


Korelácia, koeficient korelácie

Korelácia je vzťah medzi dvomi veličinami. Korelačný koeficient je číslo, ktoré vyjadruje silu tohto vzťahu. Skúma sa sila korelácie a tvar krivky, ktorá reprezentuje závislosť a hovorí o tom či je kladná alebo záporná.

Koeficient korelácie sa definuje na dvoch štatistických súboroch a preto sa dobre zobrazuje na grafe kedy jeden súbor je vynesенý na x-ovú os a druhý na y-ovú os a preložená priamka vyjadruje koreláciu.

Najprv sa ale naučme čo korelačný koeficient hovorí.

<https://www.youtube.com/watch?v=11c9cs6WpJU&t=2s>




Najprv sa ale naučme čo korelačný koeficient hovorí.


Povedzme že v súradnicovom systéme x,y máme takúto priamku a na priamke máme takto usporiadané body Koeficient korelácie **r** bude v tomto prípade kladný, lebo všetky body ležia na priamke a priamka má kladný sklon. Ide o **kladnú koreláciu**, lebo keď sa zvyšuje x, tak sa zvyšuje aj y. Existuje priamy vzťah (závislosť) medzi x a y.




Pri ďalšom prípade máme body opäť na priamke, ale priamka klesá. Korelačný koeficient sa preto bude rovnať zápornej hodnote. Keď x rastie, y klesá. V tomto prípade máme nepriamy (inverzný) vzťah a **zápornú koreláciu**.




V treťom prípade nebu ležať body na priamke, ale **budú rozptýlené blízko priamky** a tým majú dosť lineárny vzťah. Nie však 1 ako to bolo v prvom prípade, ale **r** sa bude nachádzať niekde medzi **0** a **1**. Je to kladné lebo priamka stúpa a má kladný sklon. Ak by sme vypočítali korelačný koeficient mohol by byť napr. $r = 0,8$



Ak by sme mali podobnú priamku, ale body by boli od nej viac vzdialené (rozptýlené) hodnota **r** bude nižšia napr. 0,7 alebo 0,6. Hodnota **r** by sa teda opäť nachádzala medzi 0 a 1 ale oproti predchádzajúcemu prípadu by bola kvôli väčšiemu rozptilu nižšia.



Teraz nebude existovať žiadna korelácia lebo máme iba všade náhodné body. V takejto situácii je **r** blízko 0 čo vyjadruje to že neexistuje žiadna zjavná korelácia. Takto nám koeficient hovorí o sile lineárneho (priameho) vzťahu medzi dvoma premennými



Ak premenné nebudú mať priamy vzťah **r** bude blízko 0. Ak existuje silný priamy vzťah **r** bude blízko 1 a podľa sklonu priamky bude mať vzťah kladnú alebo zápornú hodnotu.

V druhej časti uskutočníme výpočet korelačného koeficientu.

Majme dva štatistické súbory $X = [1, 2, 3, 4, 5, 6]$ a $Y = [2, 4, 7, 9, 12, 14]$ ktorých prvky sú reprezentované premennými malé x a y. Úlohou je vypočítať koeficient korelácie medzi týmito dvomi premennými:

1. Pripravíme si hodnoty ktoré budeme pri výpočte korelačného koeficientu potrebovať

	x	y	xy	x ²	y ²
	1	2	2	1	4
	2	4	8	4	16
	3	7	21	9	49
	4	9	36	16	81
	5	12	60	25	144
	6	14	84	36	196
Σ	21	48	211	91	490

$\uparrow \quad \uparrow \quad \uparrow \quad \uparrow \quad \uparrow$
 $\Sigma x \quad \Sigma y \quad \Sigma xy \quad \Sigma x^2 \quad \Sigma y^2$

2. Použijeme vzorec pre výpočet korelačného koeficientu ktorý je :

$$r = \frac{n \Sigma xy - \Sigma x \Sigma y}{\sqrt{[n \Sigma x^2 - (\Sigma x)^2] [n \Sigma y^2 - (\Sigma y)^2]}}$$

Túto rovnicu sa musíš jednoducho naučiť a najísť si spôsob na to ako si to zapamätať. Dole pod odmocninou sú tie zátvorky ktoré sa násobia rovnaké a odlišujú sa iba tým že najprv je to pre x a potom pre y. V zátvorke je to suma 2-hých mocnín x od ktorej je odpočítaná 2-há mocnina iba sumy x. To prvé číslo je ešte násobené počtom prvkov.

Hore to začína obdobne t.j. násobkom n za ktorým nasleduje suma nasobku x a y. Od tohto je odpočítaný násobok oboch súm x a y.

3. Dosadíme pripravené údaje z tabuľky do vzorca

$$\begin{aligned} r &= \frac{n \Sigma xy - \Sigma x \Sigma y}{\sqrt{[n \Sigma x^2 - (\Sigma x)^2] [n \Sigma y^2 - (\Sigma y)^2]}} = \frac{6 \times 211 - 21 \times 48}{\sqrt{[6 \times 91 - (21)^2] [6 \times 490 - (48)^2]}} = \frac{1\,266 - 1\,008}{\sqrt{[546 - 441] [2\,940 - 2\,304]}} \\ &= \frac{258}{\sqrt{[105] [636]}} = \frac{258}{\sqrt{66\,780}} = \frac{258}{258,42} = 0,998 \end{aligned}$$

Takže hodnota korelačného koeficientu je veľmi vysoká čo naznačuje že existuje veľmi silný lineárny (priamy) vzťah medzi premennými x a y a skutočnosť že je kladná hovorí že sklon je pozitívny $x \uparrow \rightarrow y$